March 24th 實驗報告

今天的进展其实是非常关键的一天，而且已经从“搭框架”正式进入到“可用于论文实验的系统阶段”。我帮你系统梳理一下，从工程、实验、论文三个层面讲清楚你今天到底做到了哪一步，以及接下来该怎么走。

一、今天你完成了什么（工程层面）

今天最重要的突破，是你把整个推荐系统从“代码拼装状态”推进到了“可完整运行的实验系统”。

你完成的核心模块包括：

- ✅ **metrics.py**（评价指标 ）
  实现了 Recall@K、NDCG@K、HR@K，这些都是顶会标准指标，不是 toy 版本，而是可以直接用于论文的评价逻辑。
- ✅ **evaluator.py**（评估器）
  实现了完整的 ranking evaluation 流程，包括：
  - 用户级别评估
  - 候选集生成（排除训练集）
  - top-K 排序
  - 指标计算
- 👉 这一部分本质上就是论文里的 **Evaluation Protocol**

- ✅ **run.py**（训练 **+** 测试入口）
  你现在已经具备：
  - config 驱动
  - 数据加载
  - 模型构建（LightGCN + Semantic + SCA）
  - trainer 调用
  - evaluator 调用
- 👉 这相当于论文里的 **“实验 pipeline 实现”**

- ✅ 数据处理完整打通（这是今天最重要的一步）

你做了三件关键事情：

1. **preprocess_ml1m.py**
    - 把 `ratings.dat` → `interactions.csv`
    - 保留 user / item / timestamp
    - 转为 implicit feedback
2. **split_ml1m.py**
    - 实现 leave-one-out
    - 每个用户：
        - train：历史
        - valid：倒数第2个
        - test：最后1个
3. 成功跑通 **ML-1M**

num_users=6041
num_items=3953
train_pairs=988129

👉 这一步非常关键，因为你已经从 toy data 进入：

> 真实推荐系统数据规模

二、今天完成了论文里的哪些部分

你今天实际上已经完成了论文中最“难实现”的三块：

1️⃣ 实验数据与设置（**Experimental Setup**）

你已经具备：

- 数据集：MovieLens-1M ✅
- 数据处理：implicit + leave-one-out ✅
- 切分合理（无信息泄露）✅

👉 这部分可以直接写进论文：

We follow the leave-one-out protocol...

2️⃣ 评价指标（**Metrics**）

你实现的：

- Recall@K
- NDCG@K
- Hit Ratio@K

👉 完全符合顶会标准（SIGIR / KDD / WWW）

3️⃣ 实验流程（**Pipeline**）

你已经实现：

Data → Model → Training → Evaluation → Metrics

👉 这就是论文里的：

- Implementation Details
- Evaluation Pipeline

三、你现在处在整个项目的哪个阶段

如果把整个项目分阶段，你现在已经到这里：

阶段1：Idea（完成）
阶段2：模型设计（完成）
阶段3：代码实现（完成）
阶段4：数据接入（完成）
阶段5：实验跑通（已完成基础版）← 你现在在这里
阶段6：实验对比（还没做）
阶段7：论文结果整理（还没做）

👉 很重要的一点：

你已经不是在写代码了，你现在是在做：

> 实验科学（**Experiment Science**）

四、今天出现的问题，本质是什么

你今天遇到的所有问题，本质其实只有三类：

1️⃣ 路径问题（config / data）

比如：

data/train.csv 不存在

👉 已解决（改成 processed/ml-1m）

2️⃣ Git 误提交数据

👉 已修复（.gitignore + rm cached）

3️⃣ 运行慢

👉 本质原因：

- ML-1M + CPU
- batch_size 小
- epochs 多

👉 这是“正常现象”，不是 bug

五、当前系统是否“健康”

从你最后的 log 看：

num_users=6041 ✔
candidate≈3800 ✔
train≈100万 ✔

以及：

pos>neg=1.0 ✔
gate_mean≈0.5 ✔
ctrl_shift≈0.05 ✔

说明：

👉 模型在正常学习
👉 control 在发挥作用
👉 pipeline 没有崩

六、你现在还缺什么（非常关键）

你现在缺的不是代码，而是：

❗ 1. 实验对比（最重要）

你目前只有：

SCA（control ON）

但论文必须要有：

- SCA-on
- SCA-off
- LightGCN baseline

❗ 2. 结果表（paper核心）

你最终必须有：

Model Recall@10 NDCG@10

LightGCN
SCA-off
SCA-on

❗ 3. 实验结论

你论文的核心 claim：

> semantic control 是有效的

必须通过：

SCA-on > SCA-off

来证明

七、接下来要做什么（给你整理好的路线）

你明天开始，按这个顺序来就行：

Step 1：做“快速实验版本”（你今天还没做）

改 config：

batch_size: 1024
epochs: 1

👉 目的：快速出结果

Step 2：跑两次实验（最关键）

py run.py --config configs/sca_default.yaml
py run.py --config configs/sca_off.yaml

👉 得到：

- SCA-on
- SCA-off

Step 3：对比结果

你要看：

- Recall
- NDCG

👉 是否：

SCA-on > SCA-off

Step 4：再决定下一步

如果 control 有效果：

👉 再去做：

- LightGCN baseline
- 多 epoch
- 完整实验

八、最后我帮你总结一句话（今天的意义）

今天你真正完成的不是“写了几个文件”，而是：

> 把一个想法（**SCA**）变成了一个可以在真实数据上运行、可评估、可验证的实验系统

这是科研里最难的一步之一。

九、你现在的状态

你现在已经不是在“学推荐系统”，而是在：

> 做一篇真正可以投稿的论文项目

一、✅ 今天已经可以记录（而且必须记录）

这些属于论文中的“实验设置（**Experimental Setup**）”，不是结果。

1️⃣ 数据集信息（已经完全OK，可以写）

你今天这段：

num_users=6041
num_items=3953
train_pairs=988129
valid_pairs=6040
test_pairs=6040

👉 这部分已经是论文级数据

你可以记录为：

MovieLens-1M:
Users: 6,041
Items: 3,953
Interactions: ~1M
Train: 988,129
Valid/Test: 6,040 each

2️⃣ 数据切分方式（非常重要，今天已完成）

你已经验证：

train-valid overlap = 0
train-test overlap = 0
valid-test overlap = 0

👉 这可以写成：

> We follow a leave-one-out protocol with no overlap across splits.

3️⃣ 每用户测试样本数（关键细节）

你今天输出：

test gt per user avg = 1.0

👉 这正是顶会标准：

> Each user has one ground-truth item in the test set.

4️⃣ 候选集规模（很多人会漏写，但你有）

candidate ≈ 3800 items/user

👉 可以写：

> Full-ranking evaluation over all unobserved items.

🧠 这四块非常重要

👉 它们组成论文里的：

Dataset + Evaluation Protocol + Metrics Setup

二、❌ 今天还不能写进论文的

🚫1️⃣ 模型性能结果（最重要）

你还没有：

Recall@10
NDCG@10
HR@10

👉 因为训练还没跑完

🚫2️⃣对比实验

你还没有：

- SCA-on vs SCA-off
- LightGCN baseline

🚫3️⃣结论

你还不能说：

SCA is effective

因为还没验证

三、总结一句话（非常关键）

你今天的数据状态是：

> 实验“环境数据”已经完整，可以写进论文；但“实验结果数据”还没有产出。

四、你可以怎么记录今天的成果（建议你现在就记）

我建议你现在就写一个实验日志（以后写论文直接用）：

📓 实验记录（你可以直接复制）

Dataset: MovieLens-1M

Statistics
Users: 6041
Items: 3953
Train interactions: 988,129
Validation interactions: 6,040
Test interactions: 6,040

Split
Protocol: Leave-one-out
- Train: all but last two interactions
- Valid: second last
- Test: last

Integrity Check
- No overlap between train/valid/test
- Each user has exactly 1 test item

Evaluation
- Full-ranking
- Candidate size ≈ 3800 per user

Status
- Training pipeline connected
- Model training started
- Final metrics not yet obtained