項目邏輯

你这个项目如果按“论文证据链”的逻辑来推进，最合适的是分成五个阶段。这五个阶段不是随便拆的，而是分别对应审稿人最关心的五类问题：你的方法有没有用，为什么有用，机制是不是真的在工作，在哪些场景下更有优势，以及它能不能推广到别的数据集。你现在的项目其实已经不再是“从零开始做系统”，而是进入了“把已有方法变成完整论文证据”的阶段。所以后续推进不能再东做一点、西做一点，而是要一层一层把证据补完整。

第一阶段是主结果阶段。这一阶段的目标非常明确，就是先证明“这个方法整体上是有用的”。在这一阶段里，你只需要关心三组模型：LightGCN baseline、SCA-off、SCA-on。你要把它们放在同一个数据集、同一套切分、同一套评估协议下，统一输出 Recall@10、NDCG@10 和 HR@10，然后整理成论文里的主结果表，也就是 Table 1 的雏形。这个阶段还有一个很重要的任务，就是把实验配置记录清楚，比如 learning rate、batch size、embedding dim、epoch、best epoch、random seed、训练耗时这些，因为没有这些，结果就不具备可复现性。从论文角度讲，这一步是所有后续分析的地基；如果主结果本身不可信，后面做再多机制分析和场景分析都没有意义。

你们现在已经完成了第一阶段的 **middle** 版本，这个判断是成立的，而且这是一个很关键的进展。前面 smoke 版本只能说明 pipeline 大致能跑，但因为规模太小、训练太轻，结果容易受噪声和欠收敛影响，所以还不能作为阶段完成的依据。现在 middle 结果已经出来了，而且关系是合理的：SCA-on 高于 LightGCN，LightGCN 高于 SCA-off，至少说明三个模型的训练和评估流程是基本可信的，semantic control 也确实带来了方向正确的收益。换句话说，你们现在已经完成了第一阶段的中间验证版，可以把它理解为“第一阶段已经过了预验收”，具备继续推进后续阶段的条件。但是要注意，这还不是第一阶段的最终正式版。论文最后仍然需要一个更完整、更正式的主结果表，也就是 full 版结果。只是由于 full 版目前训练成本高、耗时长，所以你们现在完全可以先把第一阶段停留在 middle 验证状态，然后往后推进第二阶段，而把 full 版主结果留作后面补齐。

第二阶段是消融实验阶段。这一阶段不再只是回答“有没有用”，而是要回答“为什么有用”。这对你这篇论文尤其重要，因为你的核心 claim 不是简单地说“加了语义信息就变好了”，而是说 semantic control、structure-aware gate、alignment regularization 这一整套 decision-level controller 设计是有效的。那就必须通过 ablation 把每个组成部分拆开来看。具体来说，这一阶段要做的通常包括 w/o Control、w/o Gate、w/o Alignment、w/o Structure 和 Fusion variant 这些变体。每一个变体都要和 full SCA 用同一套 split、同一套 evaluator、同一套 seed，最后仍然统一输出 Recall@10、NDCG@10 和 HR@10，并整理成 Table 2。更重要的是，每一个变体都不能只是“跑一个数”，而是要能说明它到底在验证哪一条论文论点。比如 w/o Control 是验证 semantic controller 本身是不是必要，w/o Gate 是验证 gate 是否真的在做结构选择，w/o Alignment 是验证语义与结构的对齐是不是在起作用。这个阶段做完之后，你的论文就不再只是“full model 比 baseline 好一点”，而是可以开始有条理地解释“为什么这个模型这样设计”。

第三阶段是机制分析阶段。到了这一阶段，你要证明的已经不是结果层面的提升，而是机制层面的真实性。因为你这篇论文最有辨识度的地方，不是单纯拿指标说话，而是要让别人相信这个所谓的 controller 真的在控制，而不是一个包装过的 embedding fusion。这里就需要把训练过程中已经存在的机制信号拿出来做图和分析。比如 control strength 的变化曲线、gate 分布图、delta_u 和 ctrl_shift 的 epoch 级变化、pos_score 和 neg_score 的变化趋势，这些都能说明 semantic control 是否真实介入了决策。你们现在其实已经有了很不错的基础，因为从日志里看，

SCA-on 的 ctrl_shift 明显大于 0，而 SCA-off 的 ctrl_shift 一直为 0，这已经是一个非常干净的机制证据。接下来这个阶段要做的是把这些信号系统化地记录下来、可视化出来，并且整理成论文图表，比如 Figure 2、Figure 3 这类。这样你在论文里就可以不仅说“它有效”，还可以说“它是怎么起作用的”。

第四阶段是场景分析阶段。这一阶段要回答的问题是：你的方法到底在什么情况下特别有价值。因为你这篇论文一直在强调 SCA 在 sparse user、cold-start 这类行为不足的场景中更有优势，那就必须把这个 claim 变成扎实的数据。这里通常要做的是把测试用户按交互次数分桶，比如分成 Sparse、Medium、Dense 三组，分别统计三组上的 Recall@10、NDCG@10 和 HR@10，然后再单独定义一个 cold-start 阈值，筛出 cold-start 子集进行比较。这样你就可以直接对比 LightGCN、SCA-off、SCA-on 在行为信息不足时的表现，看看 semantic control 是否真的在那些场景里更能弥补结构信号的不足。这个阶段最终通常会形成 Table 3、Table 4 之类的结果。它的重要性在于，它能把你的论文从“平均指标略有提升”提升到“在关键困难场景中尤其有效”，后者往往更有说服力。

第五阶段是泛化阶段。这个阶段的任务不是再把前面所有实验重复一遍，而是用更少但更关键的实验去证明：你的方法并不是只在 MovieLens-1M 上有效。通常最合理的做法就是扩展到第二和第三个数据集，比如 Amazon-Books 和 Yelp，然后先只跑最核心的三组结果：LightGCN、SCA-off、SCA-on。这里的重点不是一开始就把所有 ablation 和全部分析都搬过去，而是先把数据预处理、split、ranking、评估流程迁移过去，确认 pipeline 正常，再用快速版和正式版逐步推进。只要你能在第二和第三个数据集上复现“方向一致”的主结果关系，这一阶段就算建立了比较好的泛化证据。这样你的论文就不会被轻易质疑成“只是在某个数据集上偶然有效”。

如果从当前项目状态来讲，你们现在的位置可以这样定义：你们已经完成了第一阶段的 **smoke** 验证，并且也完成了第一阶段的 **middle** 版本。这意味着你们已经跨过了最危险的那个阶段，也就是“怀疑 pipeline 对不对”的阶段。现在你们不是在验证“代码能不能跑”，而是在验证“论文主张是否开始站得住”。而 middle 的结果说明，它已经开始站住了。所以接下来最合理的推进方式，不是继续围着 smoke 和 middle 反复打转，而是进入第二阶段的 **ablation**。同时，把第一阶段的 full 主结果暂时作为后续补项，等有更合适的时间和计算条件时再补正式表格。

如果把后面最优先的事情再压缩成一句话，那就是：你们接下来应该先做完整消融，再做机制图和场景分析，最后再补 full 主结果和跨数据集验证。这样整个项目的推进顺序就会非常清晰：先保证主结果基本可信，再拆内部贡献，再补机制和场景，最后做泛化。这个顺序既符合你当前的资源限制，也符合论文写作的逻辑。

你现在遇到的这个问题，其实本质不是“代码跑得慢”，而是“项目推进策略该怎么选”。很多人到你这个阶段都会误判，以为 full 跑得慢说明方法有问题，或者觉得必须等 full 才能继续往下走，这两点其实都是不对的。

首先你要明确一件事：full 版本训练和评估耗时长，在推荐系统里是完全正常的现象，尤其是你现在这种设置。你每个用户都要在几千个候选物品里做排序，再做 top-K 评估，而且 LightGCN 本身还涉及全图 embedding 的传播，这些都会让 evaluation 成为最耗时的部分。所以慢并不代表模型不好，也不代表你的实现有问题，它只是说明你现在已经进入了“真实实验规模”，而不是 toy 或 smoke 阶段。换句话说，你现在慢，反而说明你在做的是对的事情。

其次，从论文角度来说，现在“不跑 full”并不会影响你项目的质量。你已经完成了 smoke 和 middle 两个层级的验证，而且 middle 结果是合理的：SCA-on 高于 LightGCN，LightGCN 高于 SCA-off，这说明 pipeline 是可信的，方法方向也是成立的。在这个前提下，你已经具备继续推进论文后续部分的条件。真正影响论文的，从来不是“有没有 full”，而是“有没有完整的证据链”。如果你现在停在这里死等 full，而不去做 ablation、机制分析和场景分析，反而会拖慢整个项目，而且论文也不会更强。

更重要的是，你要重新理解 full 的角色。full 不是用来“判断对不对”的，它只是用来“给论文提供最终表格”和“把数值再稳定一点”。真正决定你方法是否成立的，是你现在已经完成的 middle 结果，而不是那个耗时很久的 full run。所以最合理的策略不是卡在这里等，而是继续往下推进，同时把 full 当作一个后台任务慢慢跑，等它跑完再把结果替换进 Table 1。

当然，如果你确实想加快 full 的速度，也是有办法的。最有效的方法通常是在 evaluation 上做优化，比如不要每个 epoch 都做完整测试，可以改成每几轮评估一次，甚至只在最后评估；另外也可以减少候选集规模，比如对每个用户只采样一部分 candidate 再做排序，这在实验早期是完全可以接受的；还有就是避免在 evaluation 时重复计算 embedding，可以先把 user 和 item embedding 算好缓存起来，再做 ranking。这些优化不会改变方法本身，但可以显著缩短时间。

至于和老师沟通，你不应该用“我跑不动怎么办”这种被动方式去问，而是要用“我现在有两种推进策略，我更倾向于哪一种，请您确认是否合理”这样的方式。比如你可以说明你已经有 middle-scale 结果，已经验证了方法有效，现在 full 比较耗时，你打算先完成 ablation 和机制分析，把论文核心证据链补齐，同时在后台跑 full 作为最终结果。这种表达方式会让老师觉得你是有节奏、有判断地在推进项目，而不是被计算资源卡住。

总结一下，你现在最正确的选择不是停下来等 full，而是继续进入第二阶段做 ablation，同时让 full 在后台慢慢跑。等 full 结果出来，再回头补到主结果表里。这种“并行推进”的方式，既不会影响论文质量，也能最大化你的时间利用效率。你现在其实已经跨过了最难的那一步，接下来关键不是算力，而是你怎么安排节奏。

階段做法

可以，我帮你把每个阶段“该怎么做”用论文式段落讲清楚，你可以直接当项目执行说明来用。

首先是第一阶段（主结果阶段）。这一阶段的核心目标是建立方法有效性的基本证据，即证明你的模型在标准推荐任务上整体优于已有方法。具体做法是，在 ML-1M 数据集上，统一使用同一套数据划分（如 leave-one-out）、相同的评估协议以及固定的随机种子，对三组模型进行对比实验：LightGCN 作为基础结构模型，SCA-off 作为去除语义控制后的退化版本，SCA-on 作为完整模型。在训练过程中，应使用验证集选择最佳模型（而非最后一轮），并在测试集上统一输出 Recall@10、NDCG@10 和 HR@10。最终将结果整理为论文中的主表（Table 1），同时记录所有关键实验配置（如 learning rate、batch size、embedding 维度、训练轮数、最佳轮次和训练耗时）。这一阶段必须使用 full 版本设置，以保证结果的可信性和可复现性。

接下来是第二阶段（消融实验阶段）。这一阶段的目标是分析模型中各个组成模块的贡献，从而回答“为什么该方法有效”。具体做法是在保持第一阶段相同数据划分与评估协议的前提下，对模型结构进行有控制的删减，构建多个变体，例如去除 semantic control（w/o Control）、去除 gate 机制（w/o Gate）、去除 alignment 正则（w/o Alignment）、去除结构信息（w/o Structure），以及简单的融合方法（Fusion variant）。每一个变体都应只改变一个因素，避免引入额外变量，从而保证实验结论的可解释性。所有变体统一输出相同的评价指标，并整理为论文中的 Table 2。同时需要在文字中明确说明每个变体对应验证的理论假设。该阶段可以使用 middle 规模配置，以降低计算成本，同时保证结果趋势稳定。

第三阶段是机制分析阶段（**Mechanism Analysis**）。这一阶段的目标是验证模型内部机制是否真实发挥作用，而不仅仅是黑盒性能提升。具体做法是基于训练过程中已经存在的中间变量（如 control strength、gate 输出、delta 向量、score 分布等），对模型行为进行统计和可视化分析。例如，可以绘制 control strength（α）的变化曲线，观察 semantic control 在训练中的影响程度；分析 gate 的分布情况，验证其是否在进行有效的结构选择；以及统计 delta、ctrl_shift、pos/neg score 随 epoch 的变化趋势，判断语义信号是否真实改变了决策结果。这些结果应整理为图表（如 Figure 2、Figure 3），并配以简要解释说明其支持的论文论点。该阶段不需要 full 规模，使用 middle 设置即可。

第四阶段是场景分析阶段（**Scenario Analysis**）。这一阶段的目标是分析模型在不同用户条件下的表现，特别是验证其在稀疏数据或冷启动场景中的优势。具体做法是基于用户交互数量对测试用户进行分组，例如划分为 Sparse、Medium 和 Dense 三类，然后分别计算每组用户的 Recall@10、NDCG@10 和 HR@10。此外，可以定义一个冷启动阈值（如交互数低于某一值），构建 cold-start 用户子集，并单独进行评估。通过比较 LightGCN、SCA-off 和 SCA-on 在这些子集上的表现，可以验证 semantic control 在行为信息不足情况下是否具有更强的补偿能力。实验结果整理为 Table 3 和 Table 4，并在论文中解释其意义。该阶段通常使用 middle 或简化设置即可。

最后是第五阶段（泛化能力阶段，**Generalization**）。这一阶段的目标是验证模型是否在不同数据集上仍然有效，从而增强论文的普适性。具体做法是将现有实验流程迁移到其他数据集（如 Amazon-Books 或 Yelp），首先完成数据预处理与划分，并确保评估流程与 ML-1M 保持一致。在此基础上，至少运行 LightGCN 与 SCA-on 两个模型（必要时包含 SCA-off），并输出同样的评价指标。该阶段不需要重复完整的 ablation 和机制分析，而是重点验证主结果趋势是否一致。建议在这一阶段使用 full 或接近 full 的设置，以保证跨数据集结果的可靠性。

整体来看，这五个阶段构成了一条完整的论文证据链：第一阶段证明方法有效，第二阶段解释其有效性来源，第三阶段验证内部机制，第四阶段说明适用场景，第五阶段展示泛化能力。你们当前已经完成了第一阶段的 middle 版本验证，可以继续推进后续阶段，同时在后台逐步补齐第一阶段和第五阶段的 full 结果。