基于你现在这个项目的真实状态，我建议你不要推翻原有 SCA，而是做一个“三层升级版”的定会级实验方案：第一层保留你现在已经跑通的 **SCA** 主线 作为论文骨架；第二层引入老师建议的 **uncertainty-aware LLM4Rec**，把“LLM 信号是否可靠”做成新的核心研究问题；第三层把第二个 idea 缩减成一个 **robustness / noisy-signal analysis**，而不是完整转向 fake review attack。这样做的最大好处是：你既保住了当前项目已经完成的工程与结果积累，也能把 technical depth 明显拔高，而且整体故事会比单纯继续堆 ablation 更像一篇完整的定会论文。你目前仓库本身已经具备做这件事的基础，因为它已经明确是一个基于 LightGCN 的 decision-level control 框架，包含 semantic encoder、gate、sca 核心模块、evaluator 和 leave-one-out 的 ML-1M 流水线。

从论文定位上，我建议你把题目和主线从原来的“LLM-enhanced recommendation with structure-aware control”升级成“**uncertainty-aware structure-aware control for LLM-enhanced recommendation**”。这样原有 SCA 不会被否定，而是被重新解释成一个基础框架：LightGCN 提供协同过滤结构表示，semantic encoder 提供 LLM 语义偏好，gate 决定控制注入强度，alignment 保证语义空间与协同空间可对齐；在这个基础上，新增加的关键点不是再发明一个大模块，而是回答一个更强的研究问题：不是所有 **LLM** 信号都该被同等信任，模型应该根据其不确定性来决定是否以及多大程度上进行控制。这个升级和你现有代码的契合度很高，因为你的项目本来就不是 embedding fusion，而是 controlled representation，这正好给 uncertainty-aware control 留出了最自然的切入位点。仓库 README 里也已经把你的方法定义为“从 representation fusion 走向 decision-level control”，并明确给出控制表示形式 $\tilde{e}_u = e_u + g_u \odot \Delta_u$，这非常适合作为升级版方法的骨架。

完整实验方案的第一部分，仍然应该是“主结果表”，但这次不能只停留在一个中间版 checkpoint，而是要明确区分“论文核心主表”和“开发验证结果”。你已经在 middle-scale 上拿到了可信趋势：LightGCN-mid 为 Recall@10 0.0356、NDCG@10 0.0175，SCA-off-mid 为 Recall@10 0.0318、NDCG@10 0.0148，SCA-on-mid 为 Recall@10 0.0373、NDCG@10 0.0178，这说明你的 pipeline 和核心 claim 已经初步站住了，至少在统一协议下已经出现了 SCA-on > LightGCN > SCA-off 的关系。这部分在升级版方案里应被定义为“Stage A: Formal Main Results”。这里你要正式报告的模型不应只有 LightGCN、SCA-off、SCA-on，还应额外加入两类 baseline：一类是“简单语义融合 baseline”，例如把语义向量直接拼接或线性融合到 user embedding 中，用来证明你的收益不是来自“加一个额外语义分支”这么简单；另一类是“uncertainty-free semantic control baseline”，也就是保留控制结构但不建模 uncertainty，用来说明真正有用的不是 LLM 信号本身，而是“质量感知的控制”。这样 Table 1 就会从原来只有 3 个模型，扩展成至少 5 个：LightGCN、Fusion-LLM、SCA-off、SCA-on、UA-SCA（你的最终模型）。如果资源允许，再补一个更强但轻量的 side-information baseline；如果资源有限，至少也要把 Fusion baseline 做出来，因为它能直接回答审稿人最常见的质疑：你是不是只是另一种 embedding trick。

完整实验方案的第二部分，应当是“方法内部消融”，但这一次不只是原来那套 SCA 消融，而是要升级成两层消融。第一层还是原始 SCA 结构消融，即 w/o Control、w/o Gate、w/o Alignment、w/o Structure、Fusion variant。你这部分已经做出了很强的初步结果，尤其是去掉 alignment 后性能崩溃，在你整理的第二阶段结果里，w/o Alignment 的 Recall@10 和 NDCG@10 直接掉到 0，这说明 alignment 不是装饰项，而是语义信号能够稳定接入推荐决策的必要条件。同时 w/o Structure 相比完整模型有轻微下降，说明结构上下文是增益项而非全部来源；w/o Gate 和 Fusion variant 与 full model 接近，则说明你当前 middle 版本里 gate 的收益还不够显著，这恰恰为你后续引入 uncertainty-aware gate 提供了非常合理的论文动机。第二层则是升级版方法专属

消融，即 w/o Uncertainty、Uncertainty only in Gate、Uncertainty only in Alignment、Uncertainty only in Sample Reweighting、Full UA-SCA。这样 Table 2 就不再只是“原模型拆零件”，而是升级成“原模型结构 + 新贡献模块”双层验证，technical depth 会明显高一个层级。

完整实验方案的第三部分，应该是这篇升级版论文最关键的地方，也就是“**uncertainty-aware** 核心机制设计”。我建议你把 uncertainty 的实现尽量做得简单、稳定、可解释，而不是一上来做复杂概率图模型。具体做法是：让 LLM 分支除了输出语义控制向量 Δ_u 外，再输出一个标量或低维向量形式的不确定性分数 u_u。这个 uncertainty 可以有三种候选来源。第一种是最简单的 prompt confidence，让 LLM 在给出偏好判断时同时给出 yes/no confidence；第二种是多次采样一致性，用同一用户画像对偏好问题采样多次，以答案方差或分布熵作为 uncertainty proxy；第三种是模型内估计，用 semantic encoder 输出 logits 的 entropy 或 margin 构造 uncertainty。主论文里建议只放一种主实现，另外两种放附录。然后把这个 uncertainty 接入三处：一是 uncertainty-aware gate，让 g_u 不只是看结构和语义，还看这条语义信号是否可信；二是 uncertainty-aware alignment，让 alignment loss 对高置信语义更强，对低置信语义更弱；三是 uncertainty-aware sample reweighting，把高不确定性的训练样本降权，从而减少 noisy semantic supervision 对训练的污染。这样你的 final method 不会显得臃肿，因为它仍然沿着 README 里已有的 semantic encoder → gate → LightGCN → controlled representation 这条主干展开，只是加入了一个 reliability-aware decision path。

完整实验方案的第四部分，建议定义为“**confidence calibration and semantic reliability analysis**”。这是你把第一个 idea 真正做成论文贡献的地方。你不只是要证明 uncertainty-aware 模型指标更高，还要证明这个 uncertainty 本身是“有意义的”。这里可以设计三组分析。第一组是 confidence 与 ground truth 的相关性分析，把测试样本按 confidence 分桶，画出高置信、中置信、低置信下的 Hit Rate 或 Recall 曲线，看高置信是否真的更可能命中真实偏好。第二组是 confidence 与 popularity 的关系分析，检验高 confidence 是否过度集中在热门 item 上，从而回答老师提到的 echo chamber 风险。第三组是 calibration 分析，例如把 confidence bucket 的平均置信度与真实 accuracy 对齐，看看 LLM 信号是否存在过度自信。如果你的结果显示“高置信语义确实更可靠，但同时更偏热门项”，那你这篇论文就一下子从“用了 LLM 做增强”升级成“分析了 LLM 语义在推荐系统里的可靠性与偏置特征”，这是非常像定会论文的研究问题组织方式。

完整实验方案的第五部分，正好用来吸收老师提的第二个 idea，但我强烈建议你把它写成“**robustness to noisy or manipulated semantic signals**”，而不是完整 fake review attack。也就是说，你不真的去做大规模虚假评论注入、账号行为模拟和时序攻击，而是做一个更干净、更可控、更贴近你模型的实验：对 **LLM** 语义信号施加受控噪声。具体可以有三种设置。第一种是 label-flip noise，即把一部分语义偏好判断反转，模拟 LLM 错误理解用户意图；第二种是 confidence corruption，即保留判断方向但扰乱 confidence，模拟“自信但错误”的危险信号；第三种是 popularity-biased noise，即让被污染的语义更偏向热门 item，模拟 echo chamber 或评论操纵所导致的曝光偏移。然后比较 Fusion、SCA-on、UA-SCA 在 0%、10%、20%、30%、40% 噪声下的性能衰减速度。这样你就等于把第二个 idea 的“攻击性”压缩成了一个非常强的 robustness section：如果 naive semantic control 在噪声增加时快速崩溃，而 uncertainty-aware control 下降更慢，那么你就既回应了老师关于“LLM 会不会错、错了怎么办”的担忧，也不用把整篇论文转到安全攻防方向去。这一节完全可以作为 4.6 或 4.7 的 robustness analysis，分量足够，但不会让主线跑偏。

完整实验方案的第六部分，仍然应该保留你原本项目里很适合做的“机制分析”。你现在已经在日志里观察到一个非常有价值的现象：在 SCA-off 中 ctrl_shift 恒为 0，而在 SCA-on 中 ctrl_shift 始终为非零，这本身就是一个极其干净的机制证据，说明 semantic control 不是写在公式里的摆设，而是真正进入了决策。你在 middle 结果中也已经观察到这一点。升级版里建议把机制图系统化成四张：第一张是 ctrl_shift、delta_abs、gate_mean 随 epoch 的演化图，证明控制路径真实激活；第二张是 uncertainty 分布与 gate 值的关系图，证明模型确实会在高不确定性下收缩控制强度；第三张是正负样本 score gap 在不同模型中的变化图，说明 semantic control 如何改变排序决策；第四张是代表性 case study，展示一个 sparse user 在高置信语义辅助下是如何从错误 item 切换到正确 item，和一个低置信样本在 uncertainty-aware 模型下是如何被“谨慎处理”的。这样机制分析就不再只是“看门控均值没塌缩”，而是能把 SCA 与 UA-SCA 的内部差异非常直观地讲出来。

完整实验方案的第七部分，建议你一定保留“**sparse / cold-start** 场景分析”。这本来就是你项目逻辑里最适合做、也最容易讲出价值的一段。因为如果平均指标只比 LightGCN 高一点点，审稿人很可能会说提升有限；但如果你能证明在 sparse user 或 cold-start 子集上，UA-SCA 的收益显著大于 dense user，那论文说服力会大很多。这里的做法可以沿用你之前规划的方案：按用户交互次数把测试用户分为 Sparse、Medium、Dense 三组，并额外定义一个 cold-start 阈值；然后在每个子集上比较 LightGCN、Fusion、SCA-on、UA-SCA 的 Recall@10、NDCG@10、HR@10。若结果显示行为越稀疏、uncertainty-aware semantic control 的收益越明显，那么你整篇论文的故事就会非常完整：当协同信号充分时，模型可以主要依赖结构；当协同信号不足时，语义信号很有价值，但前提是要辨别其可靠性。这一逻辑比单纯说“我们加了 LLM 所以更好”强得多。

完整实验方案的第八部分，是“跨数据集泛化”。这里我建议你采用你之前已经形成的分阶段策略：不要一开始就把所有分析在第二第三个数据集上全复刻，而是先确保 ML-1M 做成一条完整证据链，然后只把最核心的主结果迁移到第二个数据集，例如 Amazon-Books，再视情况扩到 Yelp。你的仓库目前已经把 ML-1M 的数据管道、split 和 full-ranking evaluation 写得比较清楚，MovieLens-1M 的规模、切分方式和候选规模也都在 README 中明确。因此升级版实验可以采用“1+1+optional 1”的设计：在 ML-1M 上做 full evidence chain；在 Amazon-Books 上做 Main Results + limited ablation；在 Yelp 上如果资源允许就做 Main Results 复现趋势。这样既有泛化证据，又不会让工程复杂度失控。

从论文结构角度，升级版实验章节最好围绕五个明确的研究问题来组织。RQ1：相比标准协同过滤与简单语义融合，decision-level semantic control 是否有效？RQ2：uncertainty-aware control 是否比 uncertainty-free control 更优？RQ3：uncertainty 是否真的反映了语义信号的可靠性，而非随机噪声？RQ4：在 noisy semantic signals 下，uncertainty-aware control 是否更鲁棒？RQ5：该方法是否在 sparse / cold-start 用户和跨数据集场景中仍然有效？这样一来，你的实验就不会显得像“做了一堆表”，而是每一张表、每一组图都在回答一个清楚的研究问题。这种写法非常符合定会论文的审稿阅读方式。

如果把整个升级版方案压缩成执行路线，我建议你按四个波次推进。第一波先把 ML-1M 的正式主结果和原始 ablation 固化，确保 LightGCN、Fusion、SCA-off、SCA-on 全部在统一协议下可复现。第二波在现有 SCA 上实现 uncertainty-aware gate、uncertainty-weighted alignment 和简单的 uncertainty estimation，跑出 UA-SCA 主结果和专属消融。第三波做 confidence calibration、popularity bias 和 noisy semantic signal robustness 三类分析，把两个老师建议的 idea 正式接进来。第四波再做 sparse/cold-start 和第二数据集泛化。这样安排的好处是，每一波都能独立产出论文材料，不会出现“全都改了一半但没有一张能交代清楚的表”。

最后给你一个最核心的判断：这次升级版最忌讳的不是“想法不够多”，而是“想法太多导致主线发散”。所以你必须始终守住一句主叙事：**SCA** 提供了 **decision-level semantic control** 的基础框架，而升级版论文的真正贡献，是证明 **LLM** 语义信号既有价值也有风险，因此推荐系统需要 **uncertainty-aware control**，而不是无差别吸收语义偏好。只要你整套实验都围绕这句话展开，老师给你的两个 idea 和你原来的版本就不是三条线，而会自然合成一篇完整的、定会风格很强的论文。

Uncertainty-aware Structure-aware Semantic Control for LLM-enhanced Recommendation
USCRec

邮件 / 回复内容（可直接用）：

老师您好，

感谢您的详细建议，我这两天根据您的反馈对实验部分做了一轮系统补充，并整理了当前阶段的进展，想和您同步一下。

目前我已经在 ML-1M 数据集上完成了一个中等规模（middle-scale）的实验闭环，包括 baseline 对比和完整消融实验。具体来说：

1）在 baseline 对比方面，我补充并统一跑通了 LightGCN、SCA-off 和 SCA-on 三个模型，在同一数据划分和评估协议下进行比较。目前结果呈现出比较稳定的趋势：SCA-on 略优于 LightGCN，并明显优于 SCA-off，这说明当前 pipeline 和方法方向是基本可信的。

2）在 ablation 方面，我已经补齐了 w/o Gate、w/o Alignment、w/o Structure 以及 Fusion variant 等变体，并在同一设置下进行对比。其中一个比较关键的现象是：去除 alignment 后模型性能几乎完全崩溃（Recall@10 ≈ 0），这说明语义空间与协同表示之间的对齐约束是必要条件，而不是简单的辅助正则。

3）此外，从训练日志中可以观察到一些机制层面的信号，例如 SCA-on 中 ctrl_shift 始终为非零，而 SCA-off 中为 0，这表明语义控制确实在决策过程中起作用，而不是简单的表示叠加。

整体来看，目前已经完成了第一阶段（主结果 middle-scale 验证）和第二阶段（消融实验）的基础版本，实验结构基本成型。

关于您提到的 technical depth 不够的问题，我这边也认真思考了一下。确实目前的方法更多是在结构层面引入 LLM 信号，还没有从“信号质量”角度去建模其可靠性。

基于您的建议，我目前更倾向于沿着 uncertainty-aware LLM4Rec 这个方向继续推进，而不是直接转向 injection / attack 方向。主要考虑是：

- uncertainty 建模可以直接建立在当前 SCA 框架上，不需要推翻已有实现；
- 可以自然扩展现有的 gate / alignment 机制，例如根据 LLM 输出的置信度动态调节 control 强度或对齐权重；
- 同时也可以设计额外分析，例如 confidence 与 ground truth 的相关性、与 item popularity 的关系等，从而增强方法的研究深度。

我下一步的计划是，在现有 SCA 框架上引入一个简单的 uncertainty estimation（例如基于 LLM 输出一致性或置信度），并探索：

- uncertainty-aware gating
- uncertainty-aware alignment weighting
- 以及基于 uncertainty 的 sample reweighting

同时配合分析实验，验证 LLM 信号在不同置信度下的有效性差异。

想请教您，这样在当前框架上引入 uncertainty-aware 扩展的方向是否合理？还是您更建议我直接往攻击 / robustness 那一类问题去转？